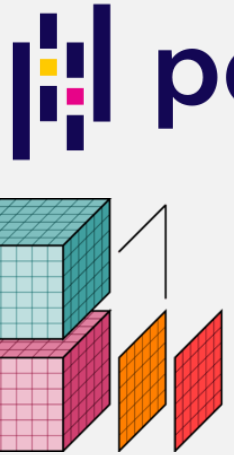

pandas

xarray

dask

Parcours de formation

Python pour les données en géosciences

Adrien Garinet & Robin Guillaume-Castel

ATTENTION !

SIGNEZ LA FEUILLE DE PRÉSENCE !!

Disclaimer

Objectifs du parcours de formation

Se familiariser avec les fonctions principales de pandas/xarray/dask

Analyser des données de géosciences de manière efficace et rapide avec python

Effectuer de grandes quantités de calculs avec une mémoire limitée/un CPU limité

Déroulement de la formation

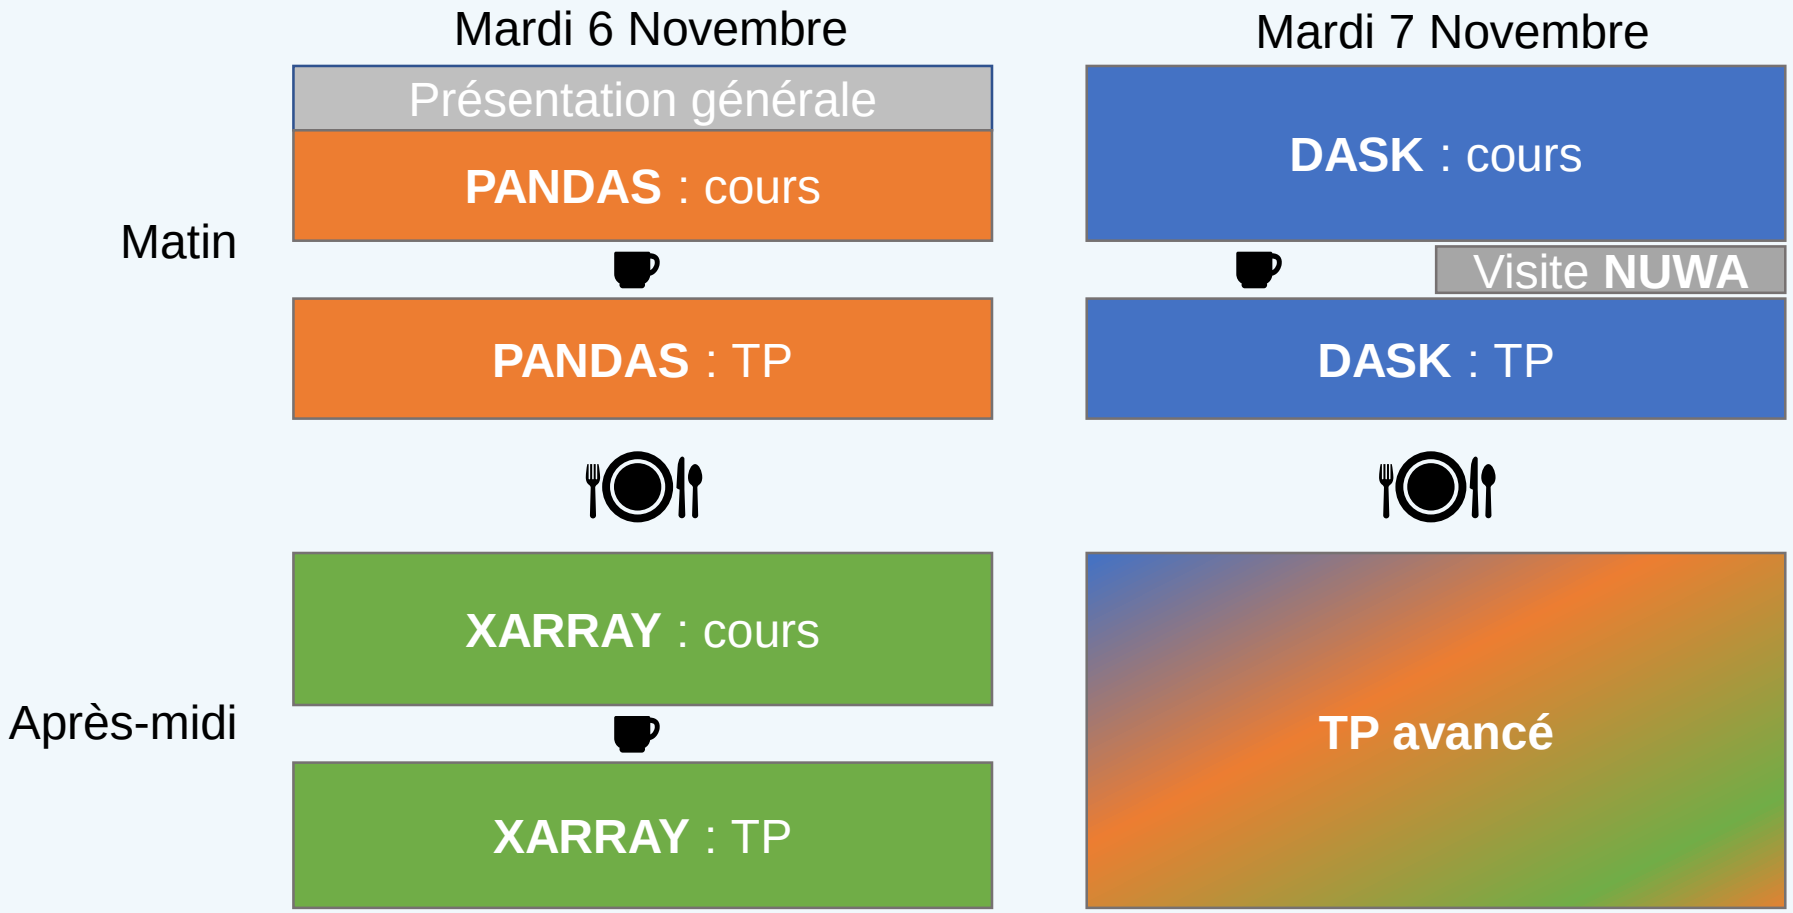

Formation Mardi

Analyse de données avec *pandas* et *xarray*

Adrien Garinet & Robin Guillaume-Castel

Objectif de la journée

Connaître l’intérêt et les fonctions générales de pandas et xarray

Présentation Générale

Pourquoi utiliser pandas et xarray?

Retour à la base: numpy.array

- Tableaux de valeurs à n dimensions

```
array([27, 90, 55, ..., 97, 76, 87])
```

```
array([[ 5, 89, 40, ..., 78, 99, 70],
       [ 2, 43, 13, ..., 91, 73, 34],
       [27,  9, 91, ..., 68, 84, 62],
       ...,
       [44, 55, 63, ..., 65, 59, 37],
       [20,  8, 14, ..., 94, 49, 16],
       [45, 37, 89, ..., 53, 65, 84]])
```

- Opérations « terme à terme » vectorielles
  - array1 + array2

- Opérations statistiques
  - np.mean(array)

Retour à la base: numpy.array

- Selection de données:
  - array[12]: accès par la position
  - Cas de n dimensions: array[3, :, 4]
- Accès aux données pas très clair

- **À quoi correspondent les données?**
- **À quoi correpondent les axes?**

Principe commun 1: l'indexation

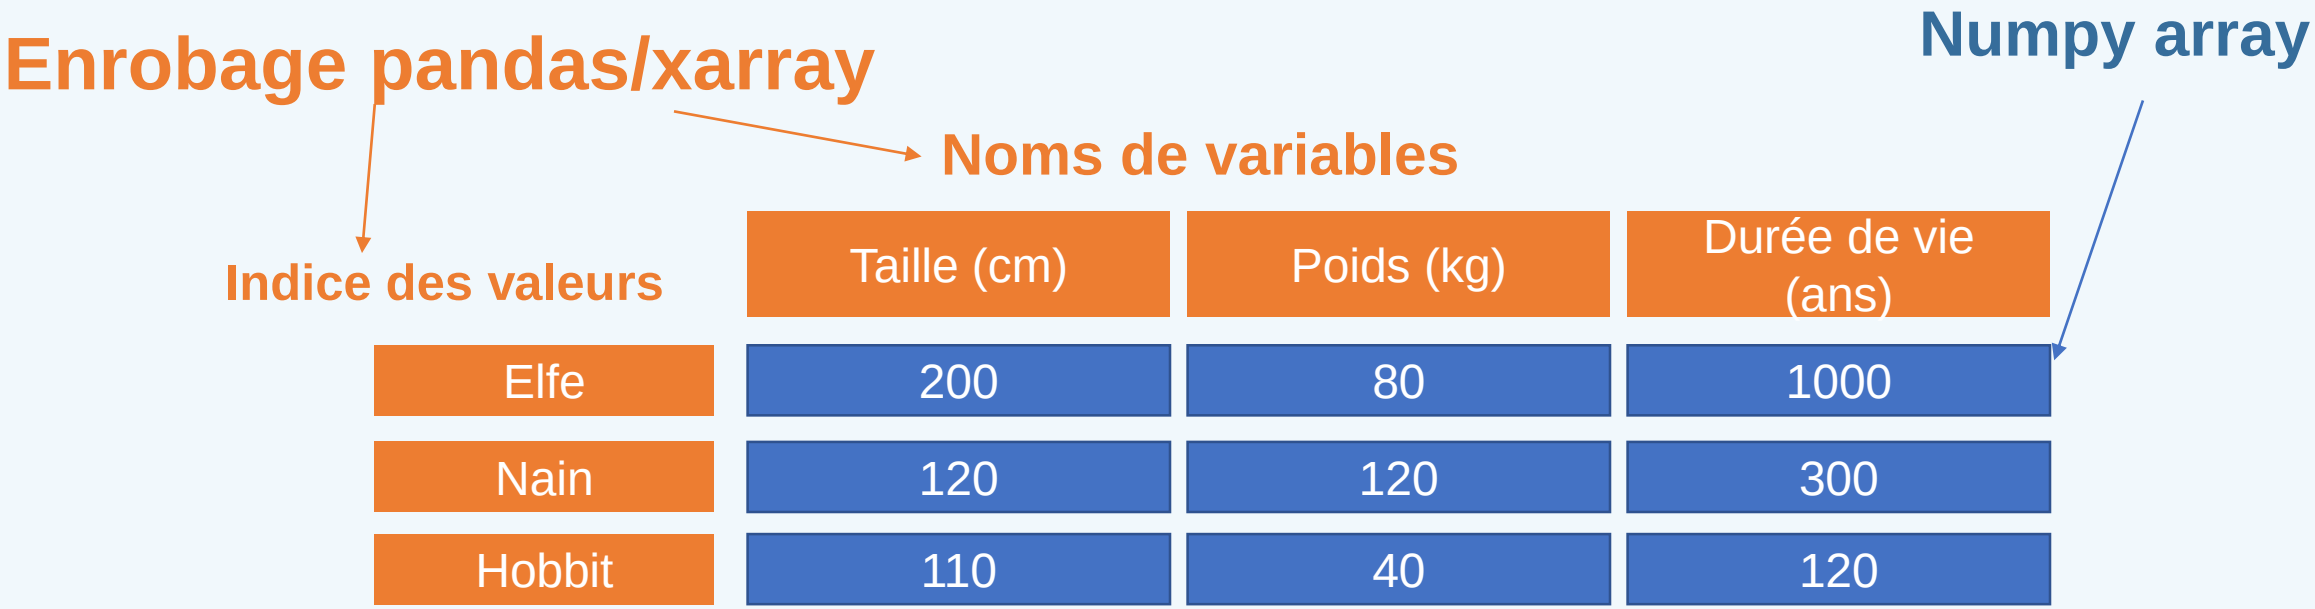

- Sélection par les indices
- Accès aux variables/dimensions par leur nom

Principe commun 2: Un large panel de format d'entrées/sorties

- Permet de lire et écrire de nombreux types de fichiers

pandas

- csv
- excel (xls, xlsx)
- txt
- json
- …

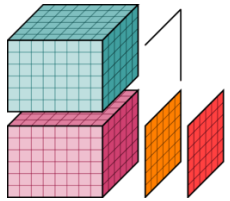

xarray

- Netcdf
- GRIB
- geoTIFF
- zarr
- …

Principe commun 3: Intégration des figures

- Intégration de matplotlib (et d'autres librairies comme hvplot, plotly, …)

Plots catégoriques

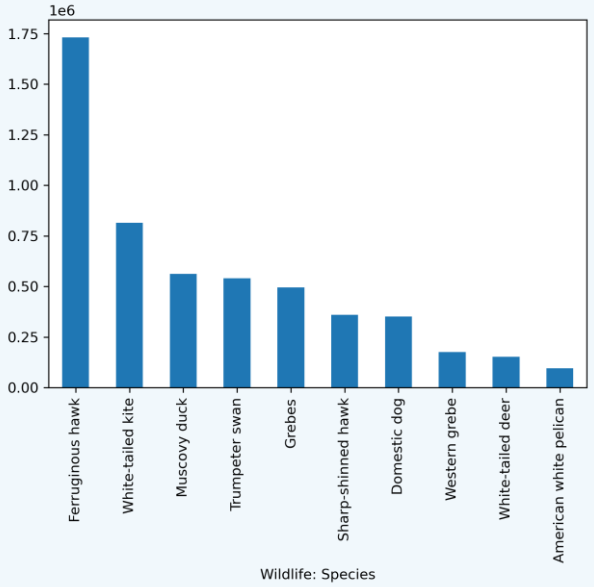

Séries temporelles

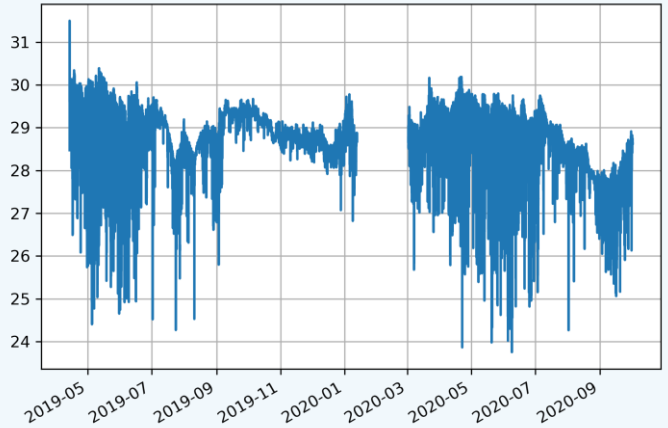

Cartes

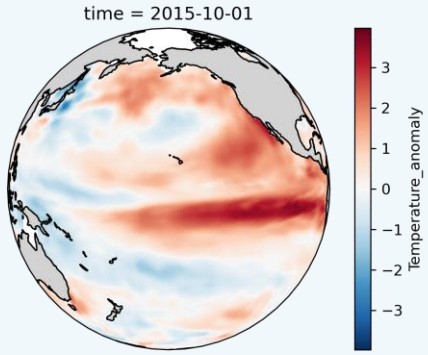

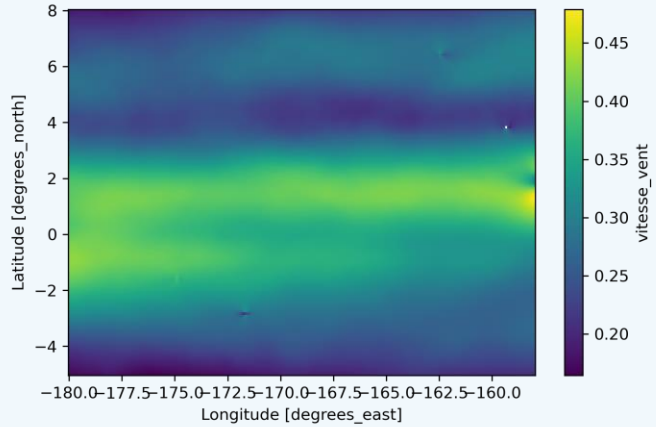

Quelques différences et spécificités

pandas

- Données plutôt unidimensionnelles
- Plusieurs types possibles (string, datetime, int, float, …)
- Plus complet en termes de fonctionnalités

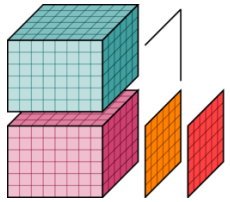

xarray

- Généralisation de pandas à plusieurs dimensions
- Parfait pour données géographiques 3d-4d

- Séries temporelles 1d
- Données catégoriques
- Données statistiques

- Données grillées climat/océan/atmosphère

Quelques ressources

- https://pandas.pydata.org/
- https://docs.xarray.dev/en/stable/
- https://gallery.pangeo.io/
- https://www.dask.org/

Des questions?

Introduction (très) rapide à Jupyter Notebook

- Cellules
- Code
- Markdown
- Sorties